


시공간 복합데이터를 활용한 전력 수요예측 개선

2024 날씨 빅데이터 콘테스트 수상작 개선



202127510 김범준 202127526 안형권
202127504 김동욱 202127534 이현진
202127507 김민구 202327503 권나영

주제

시공간 복합데이터를 활용한 전력 수요예측 개선

연구 배경 및 필요성

최근 노후화된 공동주택의 전력설비용량 부족으로 인해
동하계에 냉난방 전력수요가 급증했을 때
정전사고가 반복적으로 발생함

→ 이러한 정전사고를 사전에 예방할 수 있는 서비스가 필요함

전력기상지수 서비스

Q. 전력기상지수 서비스란?

기상변화에 따른 지역별 공동주택의 예상되는 전력수요변화를 기상예보처럼
국민들이 쉽게 인지할 수 있도록 수치화하여 최대 72h 예측해주는 서비스

A격자 00시각의 전력기상지수 = $\frac{\text{A격자 00시각의 전력수요 (또는 예상 전력수요)}}{\text{A격자 해당년도 전시간 평균 전력수요}}$

전력기상지수(elec 변수) → 우리가 예측하는 값!

데이터 소개

1) 기상 전력 학습 데이터(시계열 데이터)

Column	Description	Column	Description
NUM	기상 관측 격자 번호	afternoon	12-15시를 1, 나머지를 0 표기
STN	AWS 지점 번호	nph_ta	기온 (°C)
N	격자 내 공동주택의 수 (단위)	nph_hm	상대습도 (%)
TM	전력부하 측정날짜 (시간 단위)	nph_ws_10m	10분 평균 풍속 (m/s)
HH24	전력부하 측정시간 (1~24)	nph_rn_60m	1시간 누적 강수량, 단위(mm)
weekday	요일 (0~6)	nph_ta_chi	체감온도, 단위(°C)
week_name	주중/주말 (0/1)	denoise_ta	Nph_ta를 푸리에 변환
sin_time	HH24 변수에 sin으로 주기성 반영	denoise_hm	Nph_hm를 푸리에 변환
cos_time	HH24 변수에 cos로 주기성 반영	denoise_ws	Nph_ws_10m를 푸리에 변환
sin_month	TM의 월 값에 sin으로 주기성 반영	denoise_ta_chi	Nph_ta_chi를 푸리에 변환
cos_month	TM의 월 값에 cos로 주기성 반영	THI	불쾌지수
summer_sin	여름 특징 반영 위해 sin 변환	불쾌여부	불쾌여부 (0/1)
summer_cos	여름 특징 반영 위해 cos 변환	elec	전력기상지수

비정상성
데이터 존재!

푸리에 변환
파생변수

2) 관측 지점 정보 데이터(공간 데이터)

Column	Description	Column	Description
AWS	기상 전력 학습 데이터의 STN에 대응하는 변수	고도	AWS 관측지점의 고도 (m)
경도	AWS 관측지점의 경도	location	AWS 관측지점의 행정구역
위도	AWS 관측지점의 위도	mountain	AWS 관측지점의 산지 입지 여부
수도권 여부	AWS 관측지점의 수도권 여부		

데이터 수집 기간: 2020~2022년
실제 예측 기간: 2023년



시계열 기상 관측
변수 데이터

+

공간적인 위치
데이터



● 개선안 - 전처리, 모델링 측면

>> 수상작

결측치, 이상치 처리

본 수상작에서는
결측치, 이상치 관련 언급 X

디노이즈 기법

기상데이터의 noise를 제거하는
기법으로 푸리에 변환을 선택

예측 모델


1차 모델 : LGBM (기본 흐름 예측) + 2차 모델 : Catboost Regressor (잔차 보정)

>> 개선안


결측치, 이상치 발견 및 처리 로직 제안

-결측치 대체

- ① 결측 시점 이전/ 다음시간 존재 ② 결측 시점 이전/다음 시간 **하나만 존재**



- ③ 결측 시점 이전/다음 시간 **존재 X** -이상치 대체



푸리에 변환이 주기성 반영은 우수하나
비선형성 국지적 변화 반영에 한계가 있다고 판단




1. 웨이블릿(Wavelet) 변환 기법

2. EMD(Emperical Mode Decomposition) 기법

→ 급격한 변동 상황 예측 정밀도 향상
→ 비선형적이고 비정상적 데이터 처리 가능

LGBM + LSTM 소프트 보팅 모델 제안



→ 시계열 정보 추가 반영 가능
→ 정적 패턴 + 동적 패턴 결합하여 인식 가능

● 개선안 - 변수 측면

>> 수상작

요일, 주말을 나타내는 변수



- 1) 요일을 나타내는 weekday 변수(0~6)
- 2) 주중, 주말을 나타내는 week_name 변수(0/1)

위치를 나타내는 변수

- 1) AWS 관측지점의 위도, 경도, 고도 변수
- 2) 수도권 여부 변수(0/1)
- 3) 산지 입지 여부를 나타내는 mountain 변수(0/1)

>> 개선안

공휴일, 샌드위치 변수 추가



EDA

SHAP PLOT



쉬는 날이 elec 변수에 영향을 줌
공휴일, 샌드위치 데이 변수 추가
 Train data에 이진 변수로 추가

주거유형, 가구원 수 변수 추가

EDA

SHAP PLOT



지역별 편차가 존재하고,
 지역 내에서도 elec의 패턴이 일정하지 않음
주거유형, 가구원 수 변수 추가

- 개선방안1: 주거유형별 인구비율
- 개선방안2: 가구원 수별 인구비율
 → Train data에 인구비율을 수치형 변수로 추가
- 개선방안3: 주거유형 군집화
- 개선방안4: 가구원 수 군집화
 K-means 클러스터링을 통해 군집화 후
 → Train data에 군집을 범주형 변수로 추가




결측치 확인

elec 변수에서 5개의 결측치(null) 확인

nph_ws_10m 변수에서 169개의 결측치(-99) 확인

결측치 처리

- ① 결측 시점 이전/ 다음시간 존재
- ② 결측 시점 이전/다음 시간 하나만 존재
- ③ 결측 시점 이전/다음 시간 존재 X




결측치 개수 확인 (처리 전)
nph_ws_10m (-99.0): 169개
elec (NaN): 5개

결측치 개수 확인 (처리 후)
nph_ws_10m: 0개
elec: 0개

	Index	Before	After
0	91271	-99.0	2.15
1	257879	-99.0	3.15
2	259480	-99.0	2.45
3	319271	-99.0	2.95
4	320872	-99.0	2.40
..	...	...	...
164	5992367	-99.0	0.15
165	7447895	-99.0	1.80
166	7474199	-99.0	2.95
167	7509287	-99.0	1.15
168	7561895	-99.0	1.15

이상치 확인



주어진 데이터 중 수치형 변수만 골라 boxplot을 통해 이상치 탐색
elec column에서 300이 넘는 이상치 확인


이상치 처리

→ elec 변수의 이상치를 전후 시간의 평균값으로 대체 방법 채택!

▶ 이상치 처리 결과 비교:


	Before	After
tm	처리 전	처리 후
2870787 2022-05-30 04:00:00	elec 373.06	elec 65.75

기존 방법 : 푸리에 변환



전체 구간을 denoise
→ 국소적인 변화를 반영하지 X

방법1 : 웨이블릿 변환 기법




모델 성능(R^2 값) 하락
→ 실제 noise를 학습한 것으로 보임

방법2 : EMD 기법

내재적 반복 분해 연산으로 인해
계산 비용이 매우 커^[1]
후보에서 제외함

방법3 : STFT(Short-Time Fourier Transform) 기법



Q. **STFT(Short-Time Fourier Transform)**이란?
짧은 시간 구간으로 나눠서 푸리에 변환을 적용함으로써
시간과 주파수 정보를 동시에 표현할 수 있는 기법

<STFT 기법 선택 이유>

1. 기존 푸리에 변환이 반영하지 못했던
국소적인 변화 반영 가능
2. 계산 속도 빠름^[1]
3. 노이즈 제거와 신호 보존 간 균형이 우수^[2]

기존	MSE	MAE	R^2
1차 모델	62.7661	5.8119	0.9046
2차 모델	45.9111	4.57	0.9302


성능 개선!

STFT 적용	MSE	MAE	R^2
1차 모델	61.4784	5.7618	0.9065
2차 모델	38.1202	4.2621	0.942

elec 기준으로 군집화한 변수



타겟변수인 **elec 자체의 패턴**을 기반으로 군집화를 해보면 어떨까?



→ 1년 단위로 끊어서 elec의 패턴을 학습!

Q. STN별로 elec의 패턴을 파악하려면 어떤 방법을 써야할까?

A1. elec은 노이즈가 심한 비정상 데이터이므로
저, 중, 고주파 성분으로 분해하는 방법을 선택

A2. 주파수 별로 평균, 최댓값, 표준편차, 1주 차분의 표준편차를 고려

*최댓값 - 정전은 elec이 높을수록 위험이 높기 때문에

*1주 차분의 표준편차 - 전 주 대비 변화하는 정도를 포함하기 위하여

군집화 방법






K-means Clustering 선택

FFT + 주파수별 통계량 → K-means

1) 푸리에 변환(FFT) : 시계열을 주파수 도메인으로 변환^[3]

2) 주파수별 통계량 계산

3) K-means Clustering 적용 : 주파수별 강도의 유사성을 기준으로 패턴이 비슷한 시계열을 묶는다^[4]



군집화 평가 지표	점수
Silhouette Score	0.5494
Calinski-Harabasz Index	266.8602
Davies-Bouldin Index	0.7243




군집화 평가 지표를 통해
군집화의 성능 확인!

[3] Kiran, P., & Menon, A. S. (2025). Harmonics and neurons: A Fourier-neural approach to energy pattern analysis. Discover Applied Sciences, 7(1), 133.

[4] Kim, H., Park, S., & Kim, S. (2023). Time-series clustering and forecasting household electricity demand using smart meter data. Energy Reports, 9, 4111-4121.

● 군집 결과 분석

-군집별 클러스터 레이더 차트



Cluster0

중주파 피쳐(짧은 주기)의 반복되는 변동 존재

전체 data의 56.52% 차지

규칙적이지만, 특정 시간대에만 소비가 집중된 군집

Cluster1

고주파, 중주파 피쳐(급격한 변화, 짧은 주기)의 반복되는 변동, 1주 단위의 변동 존재

전체 data의 23.91% 차지

짧은 주기에서 불규칙적, 변동성이 큰 군집

Cluster2

모든 피쳐(급격한 변화, 긴 주기, 짧은 주기)의 변동, 1주 단위의 변동 존재

전체 data의 19.57% 차지

소비량이 전반적으로 매우 크고, 패턴이 복잡한 군집

● 군집화한 변수 적용 방법

1) 군집 번호를 변수로 취급

2) 군집별로 학습 & 검증을 따로 실행



1) One-hot Encoding을 적용하여 2차 모델에 적용


방법1	MSE	MAE	R^2
1차 모델	62.7661	5.8119	0.9046
2차 모델	46.0062	4.5641	0.93

2) 군집별로 모델을 학습하여 군집별 결과를 가중 평균

방법2	MSE	MAE	R^2
군집1	44.2709	4.5299	0.9334
군집2	42.6641	4.3651	0.9339
군집3	43.542	4.4487	0.9341
최종	-	-	0.9338

➔ 방법2를 선택!

● LGBM + LSTM 소프트 보팅 모델 도입



기존의 LGBM 모델에서의
시계열성 반영 한계를 보완하고자
LSTM 모델과의
소프트 보팅 앙상블 기법을 적용



이후, 2차 모델인
Catboost Regressor를 사용해
잔차 보정을 진행

1) 기존 LGBM 단일 모델

기존	MSE	MAE	R ²
1차 모델	62.7661	5.8119	0.9046
2차 모델	45.9111	4.57	0.9302

개선됨을
확인!

2) LGBM + LSTM 소프트 보팅 모델

소프트보팅	MSE	MAE	R ²
최종 모델	21.7356	3.3447	0.9669

● 실제 검증을 통한 과적합 여부 확인

기존 R² 값인 0.9302에 비하여 0.0367 증가라는
유의미한 R²값 향상을 보이지만
과적합의 위험이 있다고 판단하여 실제값 검증을 진행

1) 기존 LGBM 단일 모델

MSE	MAE	R ²	cc_elec
45.911	4.57	0.9302	0.978

개선됨을
확인!

2) LGBM + LSTM 소프트 보팅 모델

MSE	MAE	R ²	cc_elec
21.7356	3.3447	0.9669	0.989



실제 검증값(cc_elec)에서도 성능 상승이 있으므로
과적합이 아님을 확인

정전 위험 지수 추가 배경

전력기상지수의 목적

전력 수요가 급증할 수 있는 시기에
전력 수요 관리를 통해 **정전사고 예방**에 활용하기 위해
공동주택의 전력수요를 예측하는 전력기상지수를 개발^[5]


전력기상지수의 한계

정전사고 예방에 활용하기 위한 지수이지만
예상되는 부하량을 상대적인 수치로 제시해 줄 뿐,
정전사고 예방에 관한 정보는 제공되지 않음



전력기상지수의 본질적인 목적에 근거하여,
전력기상지수의 한계점을 보완하고자 함


기존의
전력기상지수 서비스



정전 위험 지수
추가

정전 위험 지수 제시 기준

제10차 전력수급기본계획에 의하면^[6]
기술적 최소 예비율 : 15%
기준 설비 예비율(단기) : 20%(15% + 정책적 안전 여유)



정전 위험 분류 모델

기존 Train Data에 '정전 위험 지수' 열 추가

정전 위험 지수 : 예측 elec값이 실제 elec값과
20% 이상 차이 나면 1, 아니면 0
→ binary 변수

[5] 기상서비스진흥국 기상융합서비스과. (2023). 공동주택 정전 예방을 위한 전력기상지수 개요.
[6] 산업통상자원부. (2023). 제10차 전력수급기본계획(2022~2036). 대한민국 정부.

정전 위험 분류 모델

Train Data에서 '정전 위험 지수'를 학습해 분류 모델 제작
→ 2021년 Data



분류 모델에서 사용할 변수 선정

Why? 불필요한 변수를 사용하지 않아
해석 가능성과 성능 효율성을 높이기 위하여

☒ **Embedded 방식** 선택!

- 모델이 학습 중에 어떤 변수가 예측에 도움이 되는지 스스로 판단하는 구조
- 최종적으로 누적 중요도 상위 95%에 해당하는 변수만 선택!



분류 모델은 대용량 데이터와 과적합에 강건한
LGBM Classifier 선택

정전 위험 분류 모델의 성능 평가 지표


정전 위험 분류 모델의 특성상
정전 위험을 놓치지 않는 것이 가장 중요하다고 판단

실제 정전 위험일 때, 모델이 '위험'이라고 분류한 비율인
Recall을 가장 우선으로 고려함





2022년 '정전 위험 지수'로 분류 모델 검증

Class	Precision	Recall
0(안정)	0.9993	0.9839
1(위험)	0.2503	0.8893



실제 정전 위험일 때,
대부분을 '위험'으로 잘 분류함을 확인할 수 있음!

● 최종 개선안 구현 결과



기존	MSE	MAE	R ²
기존 모델	46.1565	4.572	0.9298
최종 모델	19.552	3.0951	0.97

최종 모델 R² : 0.97
 기존 모델 대비 0.0402 증가
 → **예측력 개선!**

● 성능 측면 개선안 적절성

1) 결측치, 이상치 처리 적용

소량의 데이터라도
 결측치 처리 후
 R²가 0.004 향상!
 결측치 처리 로직을
 모델에 내장해두면
추후 결측치 발생 시 자동 보간
 → 예측 성능에 유리

2) STFT 기법 적용

기존 모델 대비 **노이즈 제거**와
신호 보존의 균형을
 효과적으로 유지하여
 성능지표 상승으로
 그 효과를 입증

3) 공휴일, 샌드위치 데이 변수 적용

주중/주말 변수로
 설명되지 않는 **특수일의**
전력 소비 패턴 변화를 반영하여,
 모델의 예측 정확도를
 향상시키는
 보완적 역할을 수행

4) LGBM+LSTM


기존 LGBM 모델의
시계열 순서 학습 한계를
보완하기 위해 LSTM과의
 소프트 보팅 결합 모델을 도입!
 테스트 성능이 학습/검증 셋과
 유사하게 유지되어
과적합 문제는 크지 않음을 확인

5) elec 기준 군집화 변수 적용


elec의 장기적, 주기적, 급진적인
주기성을 반영하기 위해
 구간을 설정하고,
 정전에 직접 관련된 대표 피처를
 추출하여 군집화를 수행!
군집화 성능 지표를 통해
 그 타당성을 확인

● 서비스 측면 개선안 적절성 및 기대효과

기존의 전력 사용량 정보 제공 시스템



개선 모델의 정전 위험 예측



기존 한국전력공사에서는
예비전력 대비 현재 부하량을 기준으로 전력 공급

기존 시스템은 전력 부하율로 전력 공급량을 결정

전력기상지수 서비스를 파워체크모바일에서 제공


미래 상태를 예측하여 정전 예방에 기여 가능

예측 모델의 국지적인 특성으로
더 세밀한 격자 단위의 전력 공급량 결정 가능

파워체크모바일 + 재난안전포털과의 협업을 통해
국민들의 정전 관련 접근성을 높일 수 있음

한계점 및 추후 개선 방향


전력기상지수의 패턴으로 클러스터링을 하였으나,
현재 가진 데이터의 변수들이
군집별 전력기상지수의 패턴을 명확하게 설명하지 못함



기상데이터에 존재하지 않는
외생 요인을 탐구하는 추후 연구로 군집 해석력 증대




현재 설정한 정전 위험 지수는 실제 정전 사례가
반영되지 않은 이론적 기준임
실제 정전 데이터의 부재로 인한
명확한 정전 기준 분석을 하지 못하였음



실제 배전으로 인한 정전 데이터가 확보된다면
정전과 전력기상지수를 분석하여
정전 특성을 명확히 할 수 있음
→ 실제 정전 예측 성능 향상 가능



정전 위험으로 분류한 데이터와
여타 데이터의 불균형으로 인해 모델의 Recall에 비하여,
Precision이 낮은 수준에 머무르는
trade-off 관계로 인한 한계점이 존재함



실제 정전 데이터를 확보와
데이터 불균형을 해소하기 위한
추가적 기법들을 사용하여 개선 가능



● 개선안 참신성/적절성, 구현 난이도/완성도

평가기준	세부 내용		페이지(pg)
제안 발표 요약 이해용이성	1. 시각화 자료로 이해를 도움 2. 수상작과 개선안의 차이점 동시 소개		p. 1~3
개선사항 참신성/ 적절성	참신성	1. elec 패턴 자체를 파악을 해서 예측 2. elec의 근본적인 목적을 찾아서 해결하고자 분류 모델 사용	1. p. 7~8 2. p. 10~11
	적절성	1. 1차 목표인 모델의 성능 개선을 위해 다양한 방식을 모색, 사용 후 상황에 맞는 개선 방법으로 변경하여 도입 2. elec을 예측하기 때문에 elec의 패턴 자체를 학습 3. elec의 목적인 정전 예측에 더 적절한 분류 모델 추가 설계	1. p. 4~6, 9 2. p. 7~8 3. p. 10~11
개선안 구현 난이도/ 완성도	난이도	1. elec 패턴 기준 군집화를 위한 주기별 변동 파악 시, 주파수별 elec의 패턴 관련 통계값 선정 2. 분류 모델의 학습 피쳐 선정 과정에서 임베디드 방식으로 중요도 기반 피쳐 선정 및 분류 모델 생성	1. p. 7 2. p. 11
	완성도	1. 실제 성능지표 비교 시 기존 모델보다 개선 2. 모델을 벗어나 서비스 자체의 개선 3. 자체적 한계점 및 추가 개선 방향 시사	1. p. 12 2. p. 10~11 3. p. 12~14